كلية العلوم التطبيقية - أيت ملول
FACULTE DES SCIENCES APPLIQUEES – AIT MELLOUL

Programmation Python
Filières AD & SIE
S5
2025/2026

TP3
Analyse et Visualisation de Données avec NumPy, Pandas et Matplotlib

➢ Contexte pédagogique

Ce travail pratique vise à renforcer la **maîtrise avancée** des bibliothèques Python les plus utilisées en **data science** :

- **NumPy** : calcul numérique, opérations vectorisées
- **Pandas** : manipulation, nettoyage et analyse de données
- **Matplotlib** : visualisation avancée

Vous avez déjà acquis :

- Les structures de données Python,
- La programmation orientée objet,
- La gestion des fichiers,
- La gestion des exceptions.

➢ Objectifs pédagogiques

À l'issue de ce TP, vous serez capable de :

- Générer et manipuler des données numériques avec **NumPy**
- Nettoyer, transformer et analyser des données avec **Pandas**
- Produire des visualisations pertinentes avec **Matplotlib**
- Structurer un mini-projet d'analyse de données
- Gérer les erreurs et produire un code robuste et lisible

➢ Structure du TP

Partie 0 – Mise en place

1. Créer un dossier de travail :

```
TP_Numpy_Pandas_Matplotlib/
├── data/
├── src/
└── figures/
```

2. Créer un environnement Python et installer :

   pip install numpy pandas matplotlib

Partie 1 – Génération et sauvegarde des données (NumPy)

- **Contexte**

Vous êtes data analyst dans une entreprise qui analyse les **ventes mensuelles de produits** sur plusieurs années.

- **Travail demandé**

1. À l'aide de **NumPy**, générer :
   - 1000 ventes,
   - Chaque vente contient :
     - ✓ product_id : entier entre 1 et 20,
     - ✓ quantity : entier entre 1 et 10,
     - ✓ unit_price : réel entre 10 et 500,
     - ✓ month : entier entre 1 et 12,
     - ✓ year : entier entre 2021 et 2024.
2. Stocker ces données dans un **tableau NumPy structuré** ou un tableau 2D.
3. Sauvegarder les données dans un fichier :

   data/ventes.csv

- **Contraintes**

- Utiliser exclusivement NumPy pour la génération
- Gérer les erreurs potentielles (ex. problème d'écriture fichier)

Partie 2 – Manipulation et nettoyage des données (Pandas)

- **Travail demandé**

1. Charger le fichier ventes.csv avec **Pandas**.
2. Afficher :
   - Les 10 premières lignes

- Les types de données
- Les statistiques descriptives

3. Ajouter une colonne :

   total_vente = quantity × unit_price

4. Simuler des données manquantes : Remplacer aléatoirement 5 % des unit_price par NaN
5. Nettoyage :
   - Remplacer les valeurs manquantes par la **moyenne du prix unitaire**
   - Vérifier qu'il n'existe plus de valeurs manquantes
6. Filtrage avancé :
   - Ventes de l'année 2023
   - Ventes dont le total dépasse 2000
7. Agrégation :
   - Chiffre d'affaires par année
   - Chiffre d'affaires par produit
   - Quantité moyenne vendue par mois

Partie 3 – Analyse avancée avec Pandas & NumPy

- **Travail demandé**

1. Calculer :
   - Le produit le plus rentable
   - Le mois avec le plus fort chiffre d'affaires
   - L'évolution annuelle du chiffre d'affaires (en %)
2. Normaliser la colonne total_vente (min-max scaling)
3. Détecter les ventes atypiques :
   - Une vente est atypique si son total est supérieur à :
   - moyenne + 2 × écart-type

Partie 4 – Visualisation des données (Matplotlib)

- **Travail demandé**

Créer les graphiques suivants (bien titrés, lisibles et sauvegardés dans /figures) :

1. Chiffre d'affaires par année (bar chart)
2. Évolution mensuelle des ventes (line plot)
3. Répartition des ventes par produit (pie chart)

4. Histogramme des montants de ventes
5. Scatter plot : quantity vs unit_price
   - **Contraintes :**

- Utiliser uniquement **Matplotlib**
- Ajouter titres, labels, grilles si nécessaire
- Sauvegarder chaque figure en .png

Partie 5 – Structuration et robustesse du code

- **Travail demandé**

1. Organiser le code en fonctions :
   - Génération des données,
   - Chargement et nettoyage,
   - Analyse,
   - Visualisation.
2. Ajouter :
   - Des **docstrings,**
   - Des **commentaires clairs,**
   - Une gestion des exceptions (try/except).
3. Créer une **classe AnalyseVentes** regroupant les traitements principaux.

➢ Livrables attendus

- Dossier du projet complet,
- Fichier ventes.csv,
- Scripts Python bien structurés,
- Dossier figures contenant les graphiques,
- Code clair, commenté et robuste.